

반려동물 헬스케어 다이어리 & 응급 대응 — 시스템 설계 요약

RAG가 근거를 가져오고, 코드가 등급을 판정하며, LLM은 그 위로만 움직인다. 대상 종 개 · 고양이 · 영무새

SKN 3차 단위 프로젝트
작성자 **오한빈** (팀장)
2026-08-04 (최종)

1 · 판단 기준 — 두 축 (문서 05)

축① 결정론은 코드로, 판단-해석만 LLM에게

조각을 붙일 때마다 3문을 던진다. ① 자연어 이해·생성이 꼭 필요한가 → 아니면 코드. ② 같은 입력에 같은 답이 나와야 하나 → 규칙으로. ③ 규칙 먼저, 안 잡히는 것만 LLM. 경계가 애매하면 코드 쪽으로 기운다.

실측이 이 축을 확인했다 — 정량 유형(dose 15건)은 규칙만으로 통과 93.3%이고 LLM을 붙여도 그대로다. 계산이 성립하는 자리에서 모델이 더할 것이 없었다.

축② 통제가 먼저, 배달이 나중

예측·검증·안전이 끝난 뒤에 UI를 만든다. 대형 LLM 기준 RAG를 먼저 완성한 뒤 sLLM으로 교체한다. 중간 점검에 보여줄 화면이 없는 것을 감수하고, 재작업과 파인튜닝 실패 리스크를 없앴다.

교체 가능성도 증명됐다 — 같은 모델을 LangChain으로 갈아 끼운 판(A-LC)이 실패 21건의 케이스 번호까지 동일했다 (D-21 · D-71).

2 · 질의 흐름 — 코드에서 뽑은 실제 노드 (문서 02 · GRAPH/BUILD.PY)



코드 — 같은 입력이면 항상 같은 답 LLM — 말을 알아듣고 말을 만든다 뒤물기 clarify 2회 · 재검색 retry → retrieve 1회 · 거절 refuse_scope / refuse_nohit / refuse_verify

③ 컨텍스트 압축은 이 경로에 없다 (D-83). 실측 근거가 393~533자이고 창은 128k라 임계 800자를 한 번도 안 넘겼다 — 한 번도 실행되지 않는 코드였다. 압축 태스크는 기간 리포트로 옮겼다. 미체택: ReAct · MCP · 멀티에이전트 · SSE 스트리밍 — "안 썼다"가 아니라 판정해서 썼다.

3 · 안전 장치 — 지표가 아니라 구조로 막는다 · 실측으로 확인됨

트리아지 하향 금지 게이트

triage_level = max(rule, llm) LLM은 등급을 낮출 수 없다. 정량 계산이 성립한 자리에서는 상황도 차단한다 (D-80).

실측 — 하향 차단 5회 · 상황 차단 6회(오류 0) · 바닥이 없는 자리에서 D-84가 3건을 더 막았다. 결과 중대 과소평가 0건 (D-09-D-80-D-84)

중 미확인 시 답변 금지

같은 물질도 종에 따라 독성이 다르다. 포유류 기준의 조류 적용은 치명적이므로, 종이 확인되지 않으면 검색 자체를 하지 않는다

경계는 슬롯 노드 한 겹이다. 검색 계층에 같은 방어를 넣는 것이 남은 과제다 (D-10)

근거 없으면 답하지 않는다

문장별 근거 검증 → 전 문장 미지지면 재검색 1회 → 그래도 부족하면 거절. 거절·뒤물기를 1급 동작으로 취급한다

문장 제거는 폐기했다 — 근거없음 문장의 다수가 등급이 시킨 행동 권고여서, 지우면 "즉시 수의사와 상담하세요"가 사라진다 (D-11·D-39)

모델은 경고를 더할 수 있고 뺄 수 없다.

같은 비대칭이 세 층에서 각자 발명됐다 — 등급(max(rule, llm) · D-09-D-80) · 문장(한국 표현 제거 · D-11-D-39) · ④ 검증(2-gram이 바닥, LLM은 조이기만 · D-91). 우연이 세 번이면 원리다.

4 · 데이터 — 라이선스 게이트가 설계를 바꿨다

검토한 출처

62

30개 도메인 약관 전수

원문 적재 가능

8

FDA · Frontiers · 농진청

사실추출 한정

38

★ 기본 경로

삭제

15

해시 + 약관 원문 기록

사실 표 → 청크

888

코드가 문장화 · 벡터DB 적재

✓ 통과 8

~ 사실추출 한정 38

× 삭제 15

✓ 통과 — 원문 청크 적재 ~ 사실추출 한정 — 원문 미적재, 사실상 뽑아 자체 문장화 × 삭제 — 약관이 용도 자체를 금지

수집 전 게이트 (D-35)

G1a 용도 금지 — artificial intelligence · train · information retrieval system

걸리면

× 중단

G1b 수단 금지 — robot · scrape

수동 취득 전환

G2 복제 허락 — 개인·비상업 허용 문언

~ 사실추출

G3 접근 비용 — 구독 · 로그인

× 중단

+ 조건 2단계 — G4 데이터베이스권 · G5 개인정보

5 · 측정 결과 — 골든셋 60건 · 동결 커밋 freeze-0803

	none 코드·규칙만	A LLM 연동	A-LC LangChain
통과	45.0%	65.0%	65.0%
상태 일치	63.3%	83.3%	83.3%
중대 과소평가	0건	0건	0건
등급 못 낸 긴급 건	25.0% 7/28	3.6% 1/28	3.6%
지연 answered p50	0.15 s	10.43 s	10.24 s
5태스크 전부 모델	0/60	60/60	60/60

가장 강한 증거 — 우발적 절제

④ 근거 검증의 조치는 300건에서 0회 실행됐다(발동 조건이 사문이었다). 그런데도 중대 과소평가는 다섯 판 전부 0건이었다.

일반적인 RAG는 사후 필터다 — 검증기가 툴리면 방어가 없다. 이 시스템은 반대로 코드가 바닥을 깔고 LLM은 그 위로만 움직인다. 안전 마진은 사후 검증이 아니라 사전 바닥에서 온다.

파인튜닝 (Qwen3-4B + QLoRA · WS3 이서는)

④ 검증 태스크 held-out 베이스 10/20 → 어댑터 20/20 (Fisher 정확검정 p = 0.0004). 분류·슬롯은 베이스도 만점이라 차이가 안 보인다.

다른 축의 측정이다 — 골든셋 60건 기준 비교군 C-D는 미측정.

6 · 지금 상태와 남은 과제

✓ 끝난 것

- 필수 산출물 넷 — 데이터·전처리 / 아키텍처 / RAG+벡터DB+LangChain 코드 / 테스트 계획·결과 보고서
- 설계 결정 86건 기록 (D-01~D-92 · 결번 6) — 전부 트레이드오프 포함
- 자료 30개 도메인 약관 전수 검토 · 판정 · 삭제 이력화
- 골든셋 60건 · 평가 하네스 · 측정 8회로 소음대 ±1건 확정
- pytest 585 passed · 추론 경로 동결(freeze-0803)

● 남은 것 (마감 후 · 04b § 7)

- 근거 적합성 검사 — 질문 물질 ≠ 출처 물질이면 근거에서 제외. substance 슬롯과 사실표 열의 문자열 대조 한 번이면 된다
- 재검색 발동 조건 재설계 — all_ungrounded 는 사문이다(300건 0회)
- ④ 배선 통합 + 재측정 (D-91) · 스트리밍(10.4초 침묵)
- prevent 유형 통과 0% · 조류 정량 역치 0행 · 개인정보 필터 미구현