

PetTriage



반려동물 헬스케어 다이어리 & 응급 대응

팀 **save the pet**

팀장 오한빈 · 이근준 · 권소라 · 이서은

목 차

WHY

왜 만들었나

.....

1. 문제의식
2. 무엇을 만들었나

HOW

어떻게 만들었나

.....

1. 데이터 · 전처리
2. 사용 기술
3. 백엔드 설계
4. 질의 파이프라인
5. 판정 구조
6. 안전 장치

PROOF

잘 되었나

.....

1. 평가결과
2. 트러블슈팅
3. 협업

DEMO

보여드립니다 .

.....

1. 한계와 다음단계

WHY - 문제의식

브이로그 다이어리 통합
일상 기록을 남기고,
실 사용이 가능하도록 저장기능

일상 관찰을 판정에 넣는다 .

" 지금 병원에 가야 하는가 ? "

인터넷 카페 · 블로그의
상충하는 비검증 정보
불안감 및 비신뢰에서 출발

" 이걸 줘도 되는가 ? "

PetTriage



WHY - 무엇을 만들었나

진단하지 않는다 . 지금 무엇을 해야 하는지에 답한다 .

응급

EMERGENCY

지금 바로 동물병원으로

전화

CALL_NOW

지금 의사에게 전화

관찰

MONITOR

집에서 지켜보기

답변불가

근거없음 답변불가

이 시스템이 내놓는 것은 지식이 아니라 결정이다 — 근거가 없으면 결정하지 않는다 .

수치는 코드가, 문장은 LLM 이

조각마다 물었다 — ① 자연어 이해·생성이 꼭 필요한가 ② 같은 입력에 같은 답이 나와야 하나 ③ 규칙으로 먼저 잡히나. 경계가 애매하면 코드 쪽으로 기울었다.



☐ 코드 — 같은 입력이면 항상 같은 답. 재현되고 감사할 수 있다 ☐ LLM — 자연어 이해와 생성. 제안만 한다

실측이 이 분업을 확인했다.

양이 있는 질문(15건)은 규칙만으로 통과 93.3% 이고 LLM 을 붙여도 그대로다 — 계산이 성립하는 자리에서 모델이 더할 것이 없었다. 반대로 계산이 없는 자리(일반 사실·조류)가 가장 약하다. 그리고 LLM 이 값을 낸 곳은 범위 밖 거절(+6건) · 사실 질의(+3건) · 증상(+2건) — 전부 말이 필요한 자리다.

HOW - 데이터 — 남의 데이터를 쓰지 않았다

수집 후 검증이 아니라 , 수집 전 게이트를 통과시켰다 · 30 개 도메인 약관 전수 확인

수집한 62 건에 게이트를 적용했다

G1a	용도 금지	artificial intelligence · train	중단
G1b	수단 금지	robot · scrape	수동 취득
G2	복제 허락	개인 · 비상업 허용 문언	사실추출
G3	접근 비용	구독 · 로그인	중단

+ 조건 2 단계 — G4 데이터베이스권 · G5 개인정보

8 건	통과	원문 청크 적재 가능 FDA · Frontiers CC BY · 농진청
38 건	사실추출 한정	원문 미적재 사실만 뽑아 우리 문장으로 재구성
15 건	삭제	약관이 AI 활용 자체를 금지 SHA-256 해시로 이력만 보존

원문 8 건 · 사실추출 38 건 — 그래서 「사실 추출」이 기본 경로가 됐다

제약이 설계를 바꿨다 . 원문을 옮기지 않고 사실만 뽑아 우리 스키마로 재구성했다 — 그 결과 코퍼스 888 청크는 전부 우리가 만든 한국어 문장이다 . 라이선스 문제가 사라졌고 , 동시에 **문장화 자체가 검증 대상**이 되어 평가에 「총 0(데이터)」를 신설했다 .

HOW - 전처리 — 문장을 검증하지 않고 필드를 검증한다

원문 → 사실 표 → 코드가 문장 생성 → 청킹 → 벡터 DB · LLM 은 이 경로에 없다



1 문장화를 LLM 이 하지 않는다

코드가 템플릿으로 만든다. 같은 표에서 항상 같은 문장이 나온다 — 재현되고, 검산할 수 있다.

2 검증 대상이 문장이 아니라 필드다

888 개 문장을 사람이 읽는 대신 표의 칸을 검사한다. 검사 범위가 한 자릿수로 줄었다.

3 출처가 끝까지 따라온다

문장마다 fact_id·source_id 가 붙어 있어, 답변의 어느 문장이 어느 자료에서 왔는지 되짚을 수 있다.

“ 원문을 옮기지 않는다 . 사실을 옮기고 출처를 밝힌다 . ”

사실 표 888 행 · 45 출처 → 코드가 문장화 (LLM 아님) → 벡터 DB 888 청크 · 총 0 (데이터) 지표로 문장화 충실도를 따로 잰다

HOW - 사용 기술 — 왜 이것을 골랐나

기술을 나열하지 않는다 . 각각이 어떤 문제를 풀려고 들어왔는지 함께 적는다

오케스트레이션

LangGraph

조건부 분기와 순환 (retry → retrieve) 이 필요했다 .
노드 18 개를 StateGraph 로 조립한다 .

LLM 연동

LangChain (ChatOpenAI)

LLM 연동에만 쓰고 벡터 DB 는 직접 다룬다 .
같은 프로토콜 뒤에서 설정 한 줄로 교체된다 .

벡터 DB

ChromaDB · 888 청크

로컬 파일 기반이라 팀원이 각자 만든다 .
인덱스는 커밋하지 않는다 .

임베딩

BAAI/bge-m3

코퍼스를 한국어 문장으로 만들었으므로
다국어 임베딩이 필요했다 .

모델

Qwen3-4B QLoRA(4bit) gpt-4o-mini

파인튜닝이 실패해도 시연은 남도록
대형 LLM 폴백 경로를 프로토콜 뒤에 유지했다 .

백엔드 · DB

FastAPI · Pydantic v2 MySQL · SQLAlchemy · JWT

안전 불변식을 문서가 아니라 스키마로 강제한다 .
계약을 어기면 응답 객체가 만들어지지 않는다 .

필수 산출물 — LangChain 연동은 「동작」 으로 증명했다

같은 모델을 ① OpenAI SDK 로 직접 부른 판과 ② LangChain 으로 부른 판을 따로 측정했다 . 통과 **39/60** 으로 같고 실패 **21** 건의 문제 번호까지 동일하다 — 배선만 된 것이 아니라 같은 판단을 같은 자리에서 낸다 . · Python 3.11 · constraints.txt 로 버전 고정 · pytest 585 통과

HOW - 백엔드 설계 — 저장소마다 담는 것이 다르다

화면 6 장 · 정적 HTML · API 와 같은 출처에서 서빙 · 계약의 단일 출처는 contracts.py 하나

MySQL

ORM (SQLAlchemy)

회원 · 반려동물 프로필 · 다이어리 · 대화 이력

ChromaDB

벡터 검색

공적 자료 문장화 청크 888 개

compute/tables

파일 (생성물)

정량 임계치 · 정성 등급 · 별칭

세 저장소가 서로를 대신하지 않는다 — MySQL 이 원본 , 벡터 DB 는 인덱스 , 규칙 표는 계산의 입력이다

로그인 · 계정

MySQL

· POST /api/auth/signup · login

· bcrypt 해시 + JWT 발급

· GET /api/users/me

반려동물 프로필

MySQL

· POST · GET /api/pets

· PATCH · DELETE /api/pets/{id}

· 0 개 → 생성 / 1 개 → 자동 선택

채팅 (질의응답)

ChromaDB

· POST /api/ask

· RAG + 규칙 계산 + 판정

· answered · clarify · refused

다이어리 · 리포트

MySQL

· POST /api/records (하루 1 건)


· GET /api/report — 기간 집계

· 병원 제출용 요약 조립

소유자 확인을 두 단계로 한다 — ① Bearer 토큰 → user_id ② (pet_id, user_id) 가 맞는 pet 이 있는가 . 없으면 404 — 남의 것도 404 로 답해 존재 여부를 흘리지 않는다 .

HOW - 질의 파이프라인 — 수치는 코드가 , 문장은 LLM 이

POST /api/ask — LangGraph 가 노드 18 개를 조율한다 · 아래는 성공 경로 9 단계



세 상태 모두 HTTP 200 — 거절은 장애가 아니라 설계된 경로다

실측이 이 분업을 확인했다 — 양이 있는 질문 15 건은 규칙만으로 통과 93.3% 이고 LLM 을 붙여도 그대로다 . 반대로 LLM 이 값을 낸 곳은 범위 밖 거절 (+6 건) · 사실 질의 (+3 건) · 증상 (+2 건) — 전부 말이 필요한 자리다 .

HOW - 판정 구조 — 등급은 추측하지 않는다

4 단계를 우리가 정하지 않았다 · 바닥은 표에서 오고 · 게이트가 세 가지를 강제한다

4 응급

지금 바로 동물병원으로 가세요

S-038 "...straight to the nearest ER."

3 전화

지금 의사에게 전화해 상태를 알려세요

S-086 "call your veterinarian to discuss..."

2 내원

오늘 중 진료를 받으세요

S-080 "Contact your vet if... worsens"

1 관찰

집에서 지켜보고, 아래 증상이 나타나면 연락하세요

S-092 "Monitor. If not resolving, seek care."

등급 이름을 우리가 정하지 않았다 — 살아 있는 코퍼스 42 건에서 “보호자에게 무엇을 시키는가” 를 모아 4 단계로 갈랐다 (D-39). 각 등급 밑의 한 줄이 그 근거 원문이다. · 숫자가 클수록 위험하다 — max() 로 하향 금지가 성립하려면 이 방향이어야 한다.

① 바닥은 어디서 오나 — rule_level 의 세 경로

【 계산 】

정량계산

섭취량 ÷ 체중 → 정량임계치.csv 15 행의 역치와 비교. 범위 · 부등호는 안전한 쪽 (낮은 값) 으로 읽는다

【 근거 】

정성

계산할 수 없는 행은 자료의 등급 표로만 말한다. 조류는 이 표에 0 행이다

【 확인 안 됨 】

양미상 · 가정

못 잔 자리는 바닥만 깔고, 못 잤다는 사실을 문장에 적는다

“ 계산해서 나온 3 ” 과 “ 양을 몰라 깔아 둔 3 ” 이 화면에서 똑같이 생겼었다. 그래서 basis 를 각주가 아니라 level 과 같은 급의 필드로 낸다 — 계약이 “ 문장에도 실렸나 ” 를 검사한다 (D-81).

② 게이트가 강제하는 세 가지 — apply_gate()

🔒 하향 금지

D-09

final = max(rule, llm). 막은 사실을 overridden 으로 남긴다 — 실측 5 건

🔒 잔 자리는 상향도 막는다

D-80

계산이 성립한 자리는 규칙이 맞다. 실측 — LLM 이 올린 10 건 중 7 건이 과대였다

🔒 조건 없는 MONITOR 금지

D-39

상승 조건이 비면 예외로 죽는다. 조건 없는 “관찰” 은 그 자체가 과소평가다

막았다는 사실을 지우지 않는다. llm_level 을 그대로 싣고 overridden · llm_capped 로 표시한다 — 조용히 무시하면 “ LLM 이 규칙과 늘 같다 ” 로 보이고, 그것은 거짓이다.

규칙도 LLM 도 등급을 못 내면, 등급을 만들지 않는다

rule 과 llm 이 둘 다 비면 apply_gate 는 ValueError 로 죽고 질의는 거절 경로로 간다 — 등급이 없는 것은 장애가 아니라 답이다. 골든셋 60 건 중 체중과 섭취량이 둘 다 있는 건은 13 건 (33%) 뿐 — 답변 셋 중 둘은 결손 상태에서 등급을 낸다. 그 결손을 숨기지 않는 것이 이 구조의 목적이다.

안전은 나중에 거르는 것이 아니라 미리 까는 것이다

일반적인 RAG 는 LLM 이 만든 답을 뒤에서 검증한다. 우리는 코드가 먼저 안전 하한선을 깔고, LLM 은 그 위에서만 움직인다.

일반적인 RAG

사후 필터

LLM 이 먼저 답을 만들고, 검증기가 잘못된 것을 걸러낸다.
방어가 마지막 한 겹에 몰려 있다.

LLM 이 답을 만든다

등급도 문장도 모델이 정한다



검증기가 거른다

환각·근거없음 탐지



사용자

● 검증기가 틀리면 방어가 없다.

vs

이 시스템

사전 바닥

코드가 물질별 최소 등급을 먼저 깬다.
LLM 은 그 바닥 아래로 내려갈 수 없다.



🔒 최종 등급 = $\max(\text{규칙}, \text{LLM})$ — 모델은 경고를 더할 수 있고 뺄 수 없다.

HOW - 안전 장치

지표가 아니라 구조로 막는다

LLM 은 등급을 올릴 수는 있어도 , 내릴 수 없다

`triage_level = max(rule, llm)` — 규칙이 낸 등급은 확정이 아니라 바닥이다

하향 금지 게이트

프롬프트로 부탁하지 않는다 .
코드가 내림을 불가능하게 만든다 .

종 미확인 시 답변 금지

포유류 기준의 조류 적용은 치명적이다 .
종이 없으면 검색 자체를 하지 않는다 .

근거 없으면 답하지 않는다

answered 인데 citations 가 비면
응답 객체 생성 자체가 실패한다 .

과소평가가 가장 나쁜 실패다 . 틀리더라도 안전한 쪽으로 틀리게 만들었다 .

PROOF - 평가 결과

골든셋 60 건 · 동결 커밋 freeze-0803

65.0%

종합 통과율

규칙만 45.0% → +20.0%p

0 건

심각한 과소평가

다섯 번 측정 전부 0 건

3.6%

응급인데 등급 못 냄

규칙만 25.0% (7/28)

동일

LangChain 연동

실패 21 건까지 완전 일치

	AI 없이	AI 연동	LangChain
통과율	45.0%	65.0%	65.0%
질문에 답한 비율	63.3%	83.3%	83.3%
위험을 낮게 봄	7.4% (2 건)	0 건	2.8% (1 건)
응급인데 등급 못 냄	25.0%	3.6%	3.6%
출처를 붙인 비율	59.0%	79.5%	79.5%
응답 시간 (중앙값)	0.15 초	10.4 초	10.2 초

가장 크게 좋아진 것

응급 28 건 중 규칙만으로는 7 건이 등급을 못 냈다. AI 를 붙여 1 건 .

대가는 속도

0.15 초 → 10.4 초 . 스트리밍 미적용이라 그동안 화면이 비어 있다 .

※ 상태 · 등급 · 필수 문구 · 금지 문구를 모두 만족해야 통과

파인튜닝 (Qwen3-4B + QLoRA) — 측정 · 작성 이서은 (WS3) · 같은 60 건이 아니라 학습셋 held-out 20 건씩 · 정확 일치

④ 근거 검증 10/20 → 20/20 (Fisher p = 0.0004) · ① 분류 · ② 슬롯은 베이스도 20/20 — 차이가 안 보인다

△ 다른 측의 측정이라 위 표와 나란히 읽지 않는다 . 골든셋 60 건 기준 비교군 C·D 는 여전히 미측정 — 학습 6,739 건 · 골든셋 누수 0 건 · 재현 커밋 71322b1

앞의 두 겁이 뚫렸는데 등급은 맞았다

골든셋 G-025 — 검색이 엉뚱한 자료를 가져왔고 근거 검증기까지 통과시켰다. 그런데도 보호자는 "지금 바로 병원으로 가세요"를 봤다.

👤 "강아지가 차고에서 부동산을 활은 것 같아요. 조금이라 괜찮겠죠?"

부동액(에틸렌글리콜) — 소량으로도 급성 신부전

방어 ①

검색
"활기" 표면어로 중독 자료 대신 개 강박장애 자료를 가져왔다

✖ 뚫림

방어 ②

④ 근거 검증
그 자료를 글자 그대로 옮긴 문장에 일치율 0.688 로 「근거있음」 도장
정작 참인 문장은 0.095 로 탈락 — 완전히 역전됐다

✖ 뚫림

방어 ③

규칙표 바닥
부동액 = 최소 4등급이 이미 깔려 있었다 (코드가 계산한다)

🔒 막음

방어 ④

하향 금지 게이트
LLM 은 1등급(관찰)을 냈다 — 치사 물질에 3등급 차이. `max(rule, llm)` 이 높였다

🔒 막음

방어 ⑤

완곡표현 제거
목록의 "관찰만" 과 모델이 쓴 "관찰하는" — 한 단어 차로 놓쳤다

⚠ 놓침

보호자가 본 것

응급

지금 바로 동물병원으로 가세요

기대 등급 4 · 실제 4 ✓

우연이 아니다 — 60건 전체에서

LLM 이 1~2 를 냈는데
코드가 3 이상으로 올린 건 10건

그중 코드가 맞았던 건 8건

LLM 이 3등급을 낸 건 4건

LLM 은 양극단으로 답한다 — "최악(4)" 아니면
"괜찮음(1)". 정답의 다수는 중간(3) 이다. 그 간극
을 코드가 메운다.

● 그리고 가장 강한 증거

④ 근거 검증의 조치는 300건에서 0회 실행됐다.
그런데도 심각한 과소평가는 다섯 판 전부 0건이
었다.

PROOF - 협업 — 같은 환경에서, 망가뜨리지 않고

규칙을 말로 정하지 않았다. 명령 한 줄과 자동 검사로 강제했다

환경을 복제한다

constraints.txt

버전을 잠근다. 실험 결과를 보고할 때 이 파일의 커밋 해시를 함께 적는다 — 누구나 같은 환경을 재현한다

make db

MySQL 을 로컬에 설치하지 않는다. 컨테이너 하나로 전원이 같은 DB 를 띄운다 (D-48)

make doctor

새 기계에서 무엇이 빠졌는지 한 줄씩 짚는다. 고치지는 않고 알려만 준다

GPU 없이도 일한다

지연 임포트

torch · transformers 를 함수 안에서만 불러온다. GPU 없는 팀원도 API 서버와 pytest 가 그대로 돈다

[api] [rag] [db] [train]

역할별로 의존성 그룹을 쪼갬다. 백엔드 담당은 학습 스택을 받지 않는다

폴백 경로 유지

파인튜닝이 늦어져도 대형 LLM 으로 시연은 남는다. 한 사람이 막혀도 팀이 멈추지 않는다 (D-21)

결정을 그 시점에 남긴다

설계 결정 기록 86 건

회의록으로 뭉뚱그리지 않는다. 맥락 · 대안 · 트레이드오프를 결정하는 그 순간에 적었다

기여를 그 자리에 표시

D-73 이서은 · D-91 오한빈 · 이서은 합의 — 누가 무엇을 바꿨는지 문서에 박혀 있다

docs/07 작업 배분

시점별 변경과 담당을 따로 추적해 중복 · 누락을 막았다

깨진 코드는 못 들어온다

CI + pytest 585 건

PR 을 올리면 GitHub Actions 가 안전장치 회귀 테스트와 ruff · mypy · pre-commit 을 자동으로 돌린다

폴더마다 README

"여기에 무엇이 들어가고 무엇이 들어가면 안 되는지" 를 그 자리에서 알 수 있다

동결 태그 freeze-0803

측정의 기준선을 커밋으로 고정했다. 누가 언제 다시 재도 같은 판이 나온다

규칙은 대부분 사고 뒤에 생겼다 — 누군가 **[db]** 그룹 없이 테스트를 돌리면 pytest 요약은 **"1 skipped"** 한 줄로만 보인다. **인증 · 프로필 25 건이 통과한 것처럼 착각한다**. 이 실측 사례를 문서에 박아 두었다. 설정도 같다 — **같은 값을 두 곳에 적지 않고** configs/*.yaml 과 .env 의 경계를 .github/CONTRIBUTING.md 로 강제한다.

DEMO - 한계와 다음 단계

숨기지 않는다

알고 있는 결함

· 10.4 초 침묵

스트리밍 미적용 — 응급 상황에서 설계 결함이다

· 지켜진 것은 등급이지 문장이 아니다

엉뚱한 출처가 붙는 경우가 남아 있다

· “ 먹여도 되나요 ” 유형 통과 0%

구조가 다른 질문이라 별도 설계가 필요하다

· 작은 모델 비교 미측정

60 건 기준으로는 아직 답하지 못했다

다음에 할 것

· 근거 적합성 검사

질문의 물질과 출처의 물질이 다르면 근거에서 제외
(부동산 사례의 근본 대책)

· 학습된 검증 모델을 실제 경로에 연결

파인튜닝으로 10/20 → 20/20 이 된 그 모델이다

· 스트리밍 · 예방 질문 경로 재설계

침묵을 없애고 , 구조가 다른 질문을 따로 받는다

이 시스템은 AI 를 믿어서 안전한 것이 아니라 , 믿지 않도록 설계해서 안전하다 .

재현 · `git checkout freeze-0803 → run_eval.py --arm none` — API 키 없이 기준선을 다시 켤 수 있다 .

감사합니다