

반려동물이 뭔가를 삼켰을 때, 지금 병원에 가야 하는지 알려주는 시스템

보호자가 평소 말투로 물으면, 검증된 자료에서 근거를 찾아 지금 무엇을 해야 하는지를 4단계 중 하나로 알려줍니다. 개 · 고양이 · 앵무새를 다룹니다.

이근준 · 권소라 · 이서은 · 오한빈(팀장)

2026-08-04 · 골든셋 60건 평가 결과

이런 식으로 동작합니다

🗣️ “강아지가 다크초콜릿을 60g 정도 먹었어요. 5kg인데 괜찮을까요?”

응급 지금 바로 동물병원으로 가세요

다크초콜릿의 테오브로민은 g당 약 16 mg이므로 60 g이면 약 960 mg이고, 체중 5 kg 기준 약 192 mg/kg입니다. 자료는 40-50 mg/kg에서 중증 징후가 관찰된다고 기록합니다.

출처 · S-034 (테오브로민 중독 역치) · S-047 (초콜릿 종류별 함량)

수치 계산은 코드가 하고, 문장은 LLM이 씁니다. 등급을 정하는 계산에는 AI가 관여하지 않습니다. 왜 그렇게 만들었는지가 이 보고서의 핵심입니다.

1 평가 결과 한눈에

골든셋(정답이 붙은 시험 문제) 60건으로 측정 · 동결 커밋 freeze-0803

종합 통과율

65.0%

39/60건
AI 없이 규칙만 쓰면 45.0%
+20.0%p

위험을 낮게 본 심각한 오판

0건

다섯 번 측정 전부 0건
가장 중요한 안전 지표

응급인데 등급을 못 낸 비율

3.6%

규칙만: 25.0% (7/28)
→ AI 연동: 1/28

LangChain 연동 검증

동일

직접 호출과 LangChain이
실패 21건까지 완전 일치

가장 크게 좋아진 것 — “모르겠습니다”가 줄었다

정답이 응급 상황인 28건 중, 규칙만으로는 7건이 등급을 못 내고 되물거나 거절했습니다. AI를 붙이자 1건으로 줄었습니다. 응급 상황에서 “모르겠습니다”는 오답과 다르지만 도움도 되지 않습니다.

환각을 막으려고 넣은 AI가, 실제로는 침묵을 줄이는 자리에서 값을 뺐습니다.

필수 산출물 — LangChain 연동 증명

같은 모델을 ① OpenAI SDK로 직접 부른 판과 ② LangChain으로 부른 판을 따로 측정했습니다. 통과 39/60으로 같고, 틀린 21건의 문제 번호까지 똑같았습니다. 연결만 해 둔 것이 아니라 같은 판단을 같은 자리에서 낸다는 뜻입니다.

2 무엇이 어려운 문제인가

“초콜릿은 개에게 나쁘다”까지는 누구나 안다. 문제는 그다음이다

① 같은 물질도 답이 다르다

종 · 체중 · 먹은 양에 따라 “지켜보세요”와 “지금 가세요”가 갈립니다. 밀크초콜릿 20 g과 다크초콜릿 60 g은 **24배** 차이입니다.


② 틀리는 방향이 대칭이 아니다

과대평가는 불필요한 병원비. 과소평가는 **동물이 죽습니다**. 두 오류를 같은 무게로 다루면 안 됩니다.

③ AI는 그럴듯하게 지어낸다

없는 수치를 자신 있게 말합니다(환각). 응급 판단에서 이것은 **그 자체로 사고입**니다.

그래서 이렇게 만들었습니다 — 코드와 AI의 역할을 나눈다



□ 코드가 하는 일 — 같은 입력이면 항상 같은 답 ■ AI가 하는 일 — 말을 알아듣고 말을 만든다

정보가 없으면 추측하지 않고 되물습니다

체중이나 먹은 양이 없으면 위험도를 계산할 수 없습니다. 이때 시스템은 **지어내지 않고 되물습니다**(최대 2회). 그리고 자료에 없는 물질이면 **모른다고 거절합니다**. **거절과 되물기를 “실패”가 아니라 정상 동작으로 취급**한 것이 이 시스템의 특징입니다.

3 답은 네 단계 중 하나입니다

등급 이름을 임의로 정하지 않고, 자료 42건이 “보호자에게 무엇을 시키는가”를 모아 갈랐습니다

1단계

관찰

집에서 지켜보고, 증상이 나타나면 연락하세요

2단계

내원

오늘 중 진료를 받으세요

3단계

전화

지금 의사에게 전화해 상태를 알려세요

4단계

응급

지금 바로 동물병원으로 가세요

핵심 장치 — AI는 등급을 올릴 수만 있고 내릴 수는 없습니다

규칙표가 먼저 **최소 등급(바닥)**을 깔고, AI가 낸 등급과 비교해 둘 중 높은 쪽을 씁니다.

$$\text{최종 등급} = \max(\text{규칙표가 정한 등급}, \text{AI가 판단한 등급})$$

AI가 “괜찮아 보인다”고 해도 규칙표가 깔아 둔 바닥 아래로는 내려가지 않습니다. 대신 규칙이 놓친 위험을 AI가 발견하면 올릴 수는 있습니다. 실제 측정에서 **AI가 등급을 낮추려 한 순간이 5번 있었고 전부 막혔습니다**.

4 실제로 있었던 일 — 그리고 왜 사고가 나지 않았는가

이 한 건이 시스템의 구조를 가장 잘 보여줍니다

🗣️ “강아지가 차고에서 부동액을 핥은 것 같아요. 조금이라 괜찮겠죠?” — 부동액(에틸렌글리콜)은 소량으로도 급성 신부전을 일으킵니다

일어난 일 ① 검색이 “핥기”라는 단어에 반응해, 중독 자료가 아니라 **개 강박장애(반복적으로 발을 핥는 행동)** 자료를 가져왔습니다.

일어난 일 ② AI가 그 엉뚱한 자료를 그대로 옮겨 답변을 썼고, 근거 검증기는 “자료에 있는 문장”이므로 **합격 도장을 찍었습니다.**

일어난 일 ③ AI는 이 건에 **1단계(관찰)**를 매겼습니다. 치사 물질에 3단계 낮은 판정입니다.

방어 장치	이 건에서	결과
검색	엉뚱한 자료를 가져옴	실패
근거 검증	자료에 있는 문장이라 통과시킴	실패
규칙표 바닥	부동액 = 최소 4단계가 이미 깔려 있었음	잠금
하향 금지	AI의 1단계를 무시하고 4단계 유지	잠금

앞의 두 겹이 뚫렸는데도 보호자는 “지금 바로 병원으로 가세요”를 봤습니다.

막은 것은 검증기가 아니라 코드가 미리 깔아 둔 바닥이었습니다.

우연이 아닙니다 — 60건 전체에서

AI가 1~2단계로 봤는데 코드가 3단계 이상으로 올린 건 **10건**

그중 코드가 맞았던 건 **8건**

AI는 양극단으로 답합니다 — “최악(4단계)” 아니면 “괜찮음(1단계)”. 정답의 다수는 중간(3단계)인데 AI가 3단계를 낸 것은 4건뿐이었습니다. 그 간극을 코드가 메웁니다.

가장 강한 증거

근거 검증 장치는 300건을 도는 동안 한 번도 조치를 실행하지 **않았습니다**(작동 조건이 너무 좁았습니다). **그런데도 심각한 과소평가는 다섯 번 측정 전부 0건이었습니다.**

일반적인 AI 시스템과 무엇이 다른가

보통의 방식 — 나중에 거른다

AI가 먼저 답을 만들고, 검증기가 잘못된 것을 걸러냅니다. 검증기가 뚫리면 방어가 없습니다.

이 시스템 — 미리 바닥을 깔다

코드가 안전 하한선을 먼저 깔고, AI는 그 위에서만 움직입니다. AI를 속여도 바닥은 못 건드립니다.

같은 원리가 세 곳에서 따로 나왔습니다 — 등급(AI는 올릴 수만 있다) · 문장(AI는 경고를 뺄 수 없다) · 근거 검증(규칙이 바닥, AI는 조이기만). **모델은 경고를 더할 수 있고 뺄 수 없다** — 이것이 이 프로젝트의 설계 원리입니다.

여기까지 나온 용어 네 개

RAG

AI가 기억에 의존하지 않고, 우리가 넣어 둔 자료에서 근거를 찾아 답하게 하는 방식

벡터 DB

문장을 숫자로 바꿔 저장해 두고, 뜻이 비슷한 문장을 빠르게 찾아 주는 저장소

골든셋

정답을 미리 붙여 둔 시험 문제 60건. 이 보고서의 모든 점수가 여기서 나옵니다

파인튜닝

작은 AI 모델에 우리 과제 데이터를 추가로 학습시켜 그 일만 잘하게 만드는 것

5 측정 결과

같은 시험 문제 60건을 세 가지 구성으로 각각 풀렸습니다

AI 없이
코드·규칙만

45.0%

+ AI 연동
직접 호출

65.0%

+ LangChain
같은 모델

65.0%

종합 통과율 — 상태·등급·필수 문구·금지 문구를 모두 만족해야 통과입니다. 기준이 엄격합니다.

	AI 없이	AI 연동	LangChain
통과율	45.0%	65.0%	65.0%
질문에 답한 비율	63.3%	83.3%	83.3%
위험을 낮게 봄	7.4% (2건)	0건	2.8% (1건)
위험을 높게 봄	3.7% (1건)	11.1% (4건)	11.1% (4건)
심각한 과소평가	0건	0건	0건
응급인데 등급 못 냄	25.0%	3.6%	3.6%
답변에 출처를 붙인 비율	59.0%	79.5%	79.5%
답변 문장 중 자료 인용	측정 불가	66.1%	66.3%
응답 시간(중앙값)	0.15초	10.4초	10.2초

※ “AI 없이”의 인용 비율은 측정 불가입니다 — AI가 없으면 검색 결과가 그대로 답변이 되어, 인용률을 재면 자기 자신을 비교하는 셈이 됩니다.

대가는 속도입니다

0.15초 → 10.4초. 그리고 답변을 조금씩 흘려보내는 방식(스트리밍)을 쓰지 않으므로, 이 10.4초 동안 **화면에 아무것도 나오지 않습니다**. 응급 상황에서 이 침묵은 **그 자체로 설계 결함**이며, 숨기지 않고 과제로 적었습니다.

“위험을 높게 봄”이 늘어난 것은

의도한 맞교환입니다. 하향을 막으면 상향이 남습니다. 불필요한 병원 방문 4건과 농친 응급 1건 중 무엇을 감수할지 정한 결과입니다.

AI는 어디에서 값을 냈나 — 질문 유형별

유형	건수	AI 없이 → AI 연동	읽는 법
범위 밖 질문	9	33.3% → 100%	“우리가 답할 수 없는 질문”을 정확히 거절하게 됐습니다 — 전건 통과
양이 있는 질문	15	93.3% → 93.3%	AI의 기여가 0입니다 — 수치 판정은 코드가 이미 완성했습니다
종에 관한 질문	9	44.4% → 66.7%	등급 정확도 100%
증상 질문	3	0% → 66.7%	등급 정확도 100%
일반 사실 질문	12	16.7% → 41.7%	계산이 없는 영역 — 가장 약합니다
정보 부족 질문	9	44.4% → 33.3%	오히려 내려갔습니다 — 미결 설계
예방 질문(“먹여도 되나요”)	3	0% → 0%	구조가 다른 질문 — 별도 설계 필요

계산이 성립하는 자리가 가장 강하고, 계산이 없는 자리가 가장 약합니다. 설계가 예측한 그대로이며, 이것이 “수치는 코드, 문장은 AI”라는 분업이 실제로 작동한다는 증거입니다.


6 이 숫자를 믿어도 되는 이유

한 번 재서 나온 값이 아니라, 여덟 번 재면서 고친 것과 움직인 것을 맞춰 본 값입니다

회차	통과율	무엇을 했나
1 · 2 · 3회	55.0 / 55.0 / 56.7%	아무것도 안 바꾸고 3번 반복 → 흔들린 건 60건 중 2건뿐 측정 오차 ±1건을 먼저 확정했습니다
4회	60.0%	고칠 항목을 지목 → 지목한 건이 그대로 움직였습니다
5회	65.0%	어느 3건이 통과할지 미리 적어 두고 맞혔습니다
6회(확정)	65.0%	오차 범위 안에서 예측대로 — 이 값을 보고합니다

우연히 오른 건이 하나도 없습니다. 측정 오차를 먼저 알아냈기 때문에, 무엇을 고치면 무엇이 움직일지 예측할 수 있었습니다.

틀린 21건을 전부 분류했습니다 (미분류 0건)



더 좋은 AI 모델로 바뀌서 해결되는 항목이 하나도 없습니다.

21건 중 12건이 설계와 시험 문제, 3건이 규칙표의 빈칸, 2건이 자료 부족입니다. “AI는 제안하고 코드가 판정한다”로 설계한 결과가 여기 나타납니다.

7 파인튜닝 결과 — 담당 이서는

작은 모델(Qwen3-4B)을 우리 과제에 맞게 추가 학습시켰을 때 무엇이 좋아지는가

작업	학습 전	학습 후
질문 분류	20/20	20/20
정보 추출	20/20	20/20
근거 검증	10/20	20/20

학습 데이터 6,739건 · 시험 문제와 겹침 0건 · 통계 검정 $p = 0.0004$

가장 중요한 작업에서 가장 크게 좋아졌습니다

분류와 정보 추출은 학습 전에도 이미 만점이라 차이가 보이지 않습니다. 반면 근거 검증은 절반을 틀리다가 전부 맞추게 됐습니다. 이 작업이 “AI가 지어낸 문장을 잡아내는” 자리이고, 프로젝트가 처음부터 핵심으로 지목한 부분입니다.

⚠ 이 표는 다른 시험지로 잦 값입니다(학습 데이터에서 떼어둔 문제). 앞의 60건 결과와 나란히 놓지 않습니다. 60건 기준의 작은 모델 비교는 아직 하지 못했습니다.

8 아직 못 한 것 — 숨기지 않습니다

알고 있는 결함

- 10.4초 침묵. 스트리밍 미적용 — 응급 상황에서 설계 결함입니다
- 지켜진 것은 등급이지 문장이 아닙니다. 엉뚱한 출처가 붙는 경우가 남아 있습니다
- “먹여도 되나요” 유형 통과 0%

재지 않은 것을 0으로 적지 않습니다

- “모순 0건”은 구조적으로 0이라 실적이 아닙니다
- 60건 기준 작은 모델 비교는 미측정 — “작은 모델이 대형을 대체할 수 있는가”에는 아직 답하지 못합니다
- 통과율 65.0%는 답변 품질이 아닙니다

다음에 할 것

- 근거 적합성 검사 — 질문의 물질과 출처의 물질이 다르면 근거에서 제외 (부동액 사례의 근본 대책)
- 학습된 검증 모델을 실제 경로에 연결
- 스트리밍 · 예방 질문 경로 재설계

이 시스템은 AI를 믿어서 안전한 것이 아니라, 믿지 않도록 설계해서 안전합니다.

재현 · `git checkout freeze-0803` → `run_eval.py --arm none` — API 키 없이 누구나 기준선을 다시 썰 수 있습니다.